

词汇搭配与人物空间：《老残游记》中"老残"的搭配词分析

一、语料与规模

本文用刘鹗《老残游记》前二十回做材料，底本为艺文印书馆电子本（"好读书柜"2014年版）。原文共126,937字；经过统一简体、分词、去标点后，得到66,282个词，约14,000个不同词形，按句切分后共5,997句。目标词"老残"出现499次，分布在525个句子里，约占全部句子8.8%，是全书最明显的叙述中心。

处理步骤很简单：先用 qhchina-data 语料库 找到老残游记原文并进行下载。其次，在 VSCode 的对话框发指令，让他创建一个 python 环境，并安装 jieba、qhchina、OpenCC 作为中英文/繁简文转化。并创建一个名为 novel.txt 的文件与 VSCode 左侧，并包含小说中文的简体版本供 AI 分析。

紧接着，让 GLM 大语言模型将小说分成句子，并用 jieba 将每个句子分成单词。随后使用 qhchina (qhchina.analytics.collocations.find_collocates) 的函数 find_collocates 来检测"老残"的统计显著性的置换，设立 p 值在 0.05 以下，并设立 window 为 horizon 的左右各 5 个词，并打印成 csv 文件。

而后发送指令：（1）将句子分成单词时，不要在单词列表中加上标点符号（：，）（2）当你过滤最终结果（"filters"参数）时，用 "load_stopwords" 移除停止词（qhchina.helpers.texts.load_stopwords），以获得停止词列表。（3）过滤掉单字符单词（只考虑两个字符或更长的单词；最小单词长度）。

并更改 horizon 间距，如更改为 10。抑或使用 sentence 来进行书写。并重复停止词和过滤字符单词的指令。

最后分别设立不同的 html 页面：《老残游记》搭配词分析 — Collocation Analysis ——此为总页面。并上传至个人 GitHub 仓库。

二、方法与统计设置

搭配词用 qhchina 的 find_collocates 计算。思路是：以"老残"为中心，看哪些词经常出现在它附近。对每一个候选词 w，我们都做一个小表格，比较"老残周围 w 出现多少次"和"老残以外 w 出现多少次"。再用 Fisher 精确检验算一个 p 值：如果 p 小于 0.05，就说明这个词和"老残"一起出现不太像随机碰巧。需要注意，p 值只说明"是否显著"，不等于"关系很强"；关系强度另看 obs/exp 比（本文称作本地比值）。检验方向用单尾 "greater"，只找被"老残"吸引的词，不找回避"老残"的词。窗口设三套：左右各 5

个词 (± 5 , 得 337 个显著搭配)、左右各 10 个词 (± 10 , 得 115 个)、整句为单位 (sentence, 得 143 个)。三套都出现的词共 42 个, 作为“老残最稳定搭配”。

三、主要结果

三窗口共同核心搭配 (节选) :

- 说话类: 说道、问道、告诉、说起; 其中“说道”出现 17 次, 本地比值 (ratio) 1.8。
- 动作姿态: 坐下、一看、作揖、拱手、慌忙; 其中“坐下”出现 13 次, 本地比值 4.2。
- 心理类: 心里、想道、诧异; 其中“心里”出现 9 次, 本地比值 2.4。
- 叙事套语: 却说、次日、前日; 其中“却说”出现 7 次, 本地比值 5.0。
- 人物: 人瑞、申东造、翠环; 其中“人瑞”出现 37 次, 本地比值 2.0。
- 地点: 门口、店里、江南、东昌府; 其中“门口”出现 7 次, 本地比值 3.6。

(由 AI 提供)

按情节看:

- 第 1 回蓬莱阁梦: 罗盘出现 9 次、汉奸 8 次、纪限仪 5 次, 但都不显著。
- 第 2—4 回行医/听书: 鼓书本地比值 11.3; 宫保出现 88 次却不显著。
- 第 4—6 回曹州查酷吏: 玉贤本地比值 7.9, 写信本地比值 9.5; 站笼被 jieba 切碎, 未进结果。
- 第 7—11 回申东造/桃花山: 申东造本地比值 9.5, 书信本地比值 23.6 (仅出现 1 次); 子平出现 56 次却不显著。
- 第 12—20 回齐河破案: 人瑞、翠环、翠花显著; 刚弼出现 27 次却不显著。

(由 AI 提供)

四、这些词说明什么

(1) 老残“爱说话”, 但说话分两层。日常用“说道”最多, 出现 17 次但比值只有 1.8, 说明它常和老残一起出现, 但并非老残独有。真正标志“他要办事”的是“写信”, 出现少但比值 9.5; 书信更高到 23.6。也就是说, 老残批评玉贤、刚弼, 不靠当面吵, 而是先打听、再写信、请别人出面。刚弼全书 27 次却从不和老残显著共现, 正好说明两人通过中间人打交道。也就说明了故事围绕老残展开, 小说结构和情节发展离不开老残。

(2) 谁围绕老残, 就是情节地图。人瑞在三种窗口都排前, 出现 37 次, 对应黄人瑞, 是老残在济南后半段的主人兼旅伴; 申东造比值

9.5, 对应曹州前治盗对策; 翠环、翠花只在整句法显著, 对应齐河赎人一段。整体看, 老残前半段固定对话者少, 后半段和人瑞、翠环接触变多。

(3) 老残可“不在场”但仍主导。桃花山谈三教那一段, 正面说话的是申子平, 出现 56 次但不显著; 书信只出现 1 次却比值 23.6。这说明老残不一定本人到场, 通过推荐人、写信、定义题, 也能把影响力延伸到别处。可称为“分身式主角”。

(4) 身体动作以“看、坐、问”为主。一看、坐下、点点头、慌忙等词很多; 几乎没有打、骂、跑。地点多为门口、店里、河堤, 时间多用次日、却说。整体像一个不断走路、住店、旁观、询问的旅行者。官保出现 88 次却不显著, 说明老残不常待在官府公务语境, 更多是“被请去建议, 但不留任”。

五、和 Woloch 人物空间理论对话

Woloch

的核心观点: 小说是人物系统, 主角的突出性是靠压缩次要人物换来的。叙事注意力是稀缺的, 在于分配给谁和边缘化谁来推动故事情节发展。

Woloch

的核心意思很朴素: 小说里的注意力有限, 主角占得越多, 次要人物通常被挤得越窄; 每个人物在书里分到的“位置”合起来, 构成人物系统。

本文结果支持三点: 第一, 老残占 8.8% 句子, 且有 42 个稳定搭配, 说明他的中心地位可量化。第二, 用“人瑞”再做一次目标词, 其人瑞的 293 个显著搭配里, “老残”以 37 次排第一, 说明次要人物自己的词汇圈也围着主角转, 这正是 Woloch 说的“次要人物偏工具化”。第三, ± 5 窗口有 278 个仅该窗口出现的临时搭配, 说明老残身边人物不断换, 中心地位靠“不断换配角”维持。

但也补充了 Woloch 两点不足: 欧洲写实小说常把人物放在家庭、客厅等固定空间, 而老残在店里、河堤、江南、东昌府之间移动, 配角像驿站一样轮流出现, 不完全是“固定配角被压缩”。另外, 老残对官保谈治河、对申东造谈治盗、通过子平传桃花山议论, 承担作者发声功能; 这种“人物替作者讲道理”的层面, Woloch 模型讲得少。

六、方法限制

不同窗口不是同一问题: ± 5 看紧邻句法, ± 10 看较宽语境, sentence 看整句事件; 取 42 个交集作为稳健核心, 本身已是人为选择。jieba 对晚清词不全准, 站笼、白子寿、玳姑、黄龙子、千日醉、返魂香等被切碎而消失; 加自定义词后高绍

殷比值 7.9、玉贤由 2 次变 3
 次才显著，但多数专名仍不显著，说明除了分词，也受共现次数太少影响。低频词比值会虚高：书信比
 值 23.6 但仅 1 次，望外、狐裘比值 11.3 也仅 3
 次。搭配词还有根本盲区：它只告诉“老残旁边有什么词”，不告诉“用谁的眼睛写老残”、有没有反讽、
 老残在场却不说话时怎样。比如第 1 回梦境先定下“观察者+诊断者”身份，但相关词到第 2
 回以后才多起来，这种“身份先给、词汇后补”的落差，只能靠细读补充。

七、结语

本文用 ± 5 、 ± 10 、sentence 三套窗口分析《老残游记》中“老残”的搭配词，把 Woloch
 的人物空间变成可数词汇分布。老残的稳定搭配——说话词分日常与写信两层、人物按情节轮流围绕、
 地点以客店河堤为主——能够量化证明他是叙述中心，且次要人物多围绕他转。但游记体配角轮替、书
 信分身、作者借老残发议论，这三件事超出了 Woloch
 以欧洲写实小说为主的模型。搭配词能画出人物空间的分布图，却画不出“谁在用什么眼光照亮他”；数
 字和细读结合，才更适合做数字人文式小说分析。