哭泣的观察者：搭配词视角下《老残游记》的人物空间

摘要

本文以刘鹗《老残游记》全二十回为语料，用搭配词分析（collocation analysis）考察主人公「老残」的词汇环境，并借此讨论 Woloch 的人物空间理论。分析以 jieba 分词、qhchina 的 find_collocates 计算，用 Fisher 精确检验（$p < 0.05$）筛选显著搭配词，平行采用窗口 ±5、±10 与整句三种共现设定。结果显示：老残的词汇卫星以言说动词（说道、问道）、感知动作（一看、坐下）、轮替出现的人物（人瑞、申东造、翠环）与旅人场所（门口、店里、河堤）为主。本文将这些结果放回小说文本中细读，论证老残是一个「以言说与观察介入、却拒绝掌权」的移动观察者；其人物空间呈「配角轮替」而非「固定配角被压缩」的结构，对 Woloch 以欧洲写实小说为底本的模型构成补充与修正。

关键词：老残游记；搭配词；Fisher 精确检验；人物空间；数字人文

一、引言：为什么数一个人物身边的词

《老残游记》自叙说：「吾人生今之时，有身世之感情，有家国之感情，有社会之感情，有种教之感情。其感情愈深者，其哭泣愈痛。」刘鹗把自己的写作比作哭泣，把小说比作一份写给时代的诊断书。那么，这位「哭泣的医生」在小说里是如何被写出来的？他身边围绕着哪些词？这些词的分布能否告诉我们一些单靠细读不容易说清的东西？

Woloch 在 *The One vs. the Many* 中提出：小说是一个人物系统（character system），叙事注意力是稀缺资源；主角的突出性（prominence）以压缩次要人物的空间为代价——「the one」与「the many」之间存在结构性张力。这一理论诞生于对欧洲写实小说（如狄更斯）的阅读，它能否描述一部晚清的、第一人称色彩浓厚的游记体小说？本文尝试用可计量的方式接近这个问题：先数出老残身边的显著搭配词，再回到文本细读这些词出现的语境，最后把两者放回 Woloch 的框架中检验。

本文的问题有三：（一）老残的词汇环境由哪些词构成，这些词在统计上是否显著；（二）这些搭配与小说的情节结构、人物设置有何对应；（三）这种分布对「人物空间」概念有何启示，支持还是修正了 Woloch 的论点。

二、语料与方法

2.1 语料与预处理

本文语料为刘鹗《老残游记》全二十回（艺文印书馆电子本，「好读书柜」2014 年版），原文 126,937 字。预处理分三步：第一，用 OpenCC 将全文统一为简体（原文含「燄」「骟」等繁体与异体字，若不统一，同一词会被拆成两个词形，直接扭曲词频统计）；第二，按中文句末标点（。！？；…）切分，得 5,997 句；第三，用 jieba 分词并剔除全部标点符号，得 66,282 个词，约 14,000 个词形。

目标词「老残」作为独立词出现 499 次，分布于 493 句，约占全部句子的 8.2%。另有 34 次出现在书名「老残游记」中（多见于回目与自叙），若按子字串计算则覆盖 525 句。本文统计一律以独立词为准，以避免书名自指造成的重复计数。

2.2 列联表与 Fisher 精确检验

搭配词分析的基本问题是：两个词倾向于彼此靠近出现（共现），这种「吸引」如何与偶然区分（Evert, "Corpora and Collocations"）？课程材料以抽红球为喻：10 颗球中 5 颗红球，抽 4 颗，期望抽中 2 颗；若实际抽中 8 颗，共现次数就是偶然预期的 4 倍。本文沿用同一逻辑。

对每一个候选搭配词 Y，先固定目标词 X（老残），建立一张 2×2 列联表：

	Y 发生（窗口内出现）	**Y 不发生**
X 发生（老残的位置）	a（观察值 O）	b
X 不发生	c	d

其中 a 是观察值 O：老残窗口内 Y 实际出现的次数。期望值 E 的算法分三步：随机抽一个词恰好是 Y 的概率 P(Y) = count(Y)/N（N 为语料总词数）；老残周围有多少个窗口位置 = count(X) × 窗口大小 × 2（左右两边）；E = P(Y) × 位置数。以本文为例：N = 66,282，count(老残) = 499，窗口 ±5 时位置数约 499 × 10 = 4,990。若 count(说道) = 108，则 P(说道) ≈ 0.0016，E ≈ 8.1——与 qhchina 输出的 exp_local = 9.5 相近（qhchina 按 Evert (2008) 的窗口模式在列联表中将目标词位置本身排除，故略有出入）。

但 O/E 有已知缺陷。课程材料举了 Evert 的例子：语料 100 万双词组中，「the Iliad」与「must also」的 O 都是 10、E 都是 1，O/E 同为 10、MI 同为 3.32，分数完全一样；但直觉上 the Iliad 强得多——Iliad 只出现 10 次，每一次前面都是 the，O = 10 已是可能的最大值；而 must 与 also 各出现 1,000 次，本来可以共现多得多。差别在列联表的 c 格：the Iliad 的 c = 0（每个 Iliad 前面都是 the），must also 的 c = 990（also 大多没有 must 在前面）。O 与 E 忽略了语料中其他的一切，我们还要看两个词**没有**共现的情况。

Fisher 精确检验正是为此设计。它固定各行各列的总数，计算在「纯属偶然」（两词相互独立）的假设下，得到当前这张表以及所有更极端的表的联合概率：

$$p = [C(a+b, a) \times C(c+d, c)] / C(N, a+c)$$

以课程中的奶茶实验为例：8 杯外观相同的茶（4 杯先牛奶、4 杯先茶），女士若全凭猜测，全部答对的概率只有 1/70 ≈ 0.014；答对 3 杯的概率约 0.243，可能只是运气。把「这张表和所有更极端的表」的概率加起来，就得到 p 值。$p < 0.05$ 意味着：在「老残与该词相互独立」的虚无假设下，观察到目前或更极端共现次数的概率不足 5%——即这次共现不太可能是随机抽样的巧合。

需要强调两点。其一，p 值衡量的是「是否显著」，不是「关系强度」；强度另看 O/E（本文称本地比值）。课程材料指出，实际用法常把 p 值当分数来排序：the Iliad 的 $p \approx 1\times10^{-10}$ 比 must also 的 $p \approx 1\times10^{-7}$ 小一千倍，两者都显著，但前者排在前——O/E 和 MI 做不到这一点。本文因此同时报告 obs（观察共现次数）、ratio（O/E）与 p 值三个量。其二，检验方向取单尾 greater，只测「观察值大于期望值」的吸引方向；「显著回避」的词是另一个问题，不在本文范围内。

2.3 三种共现设定

课程材料区分了三种「相邻」的定义：视窗法（k 个词之内）、句子法（同一句子）、语法关系法（有句法修饰关系）。本文采用前两种，平行设置三个条件：

设定	共现单位	显著搭配词数	特征
window ±5	目标词左右各 5 词	337	紧邻句法环境，含较多临时组合
window ±10	目标词左右各 10 词	115	较宽局部语境，门槛更严
sentence	同一句子（一句只计 1 次）	143	事件级共现，捕捉远距离人物与场所

三种设定不是同一问题的三种估计，而是三个不同的问题：±5 问「谁紧挨着老残」，±10 问「谁在老残附近」，sentence 问「谁与老残同处一个事件」。三者的交集（42 词）构成老残最稳定的词汇卫星，本文以它为主要证据；设定特有的词则用于情节层面的讨论。

所有设定统一应用以下过滤：剔除标点符号；用 qhchina 的 load_stopwords("zh_sim") 移除 806 个现代汉语停用词；最短词长 2（只保留双字词以上）。分析工具为 Python 3.14，jieba 0.42.1（分词）、OpenCC 1.4.2（繁简转换）、qhchina 0.2.5（搭配计算）；完整脚本与数据见随文仓库。

三、结果

3.1 三种设定共有的核心搭配

表一：三设定共有的核心搭配词（按类别，sentence 法数据）

类别	词例	obs	ratio	p
言说	说道	17	1.8	0.013
言说	问道	8	3.0	0.0036
言说	告诉	7	2.5	0.019
动作	坐下	13	4.2	4.1e-06
动作	一看	10	3.9	1.1e-05
动作	作揖、拱手、点点头、慌忙、连忙	—	—	均 < 0.05
心理	心里	9	2.4	0.0097
心理	想道、诧异	—	—	均 < 0.05
叙事套语	却说	7	5.0	2.3e-04
叙事套语	次日	9	3.6	4.6e-04
人物	人瑞	37	2.0	2.0e-05
人物	申东造	7	7.2	9.7e-06
地点	门口	7	3.6	0.0021
地点	店里	8	2.0	0.041
地点	江南、东昌府	—	—	均 < 0.05

（obs = sentence 法下与老残同句的次数；ratio = 观察值/期望值；完整数据见随附 CSV。）

3.2 情节节点上的搭配分布

表二：情节节点、实证搭配与文本证据

情节段	节点	显著搭配（数据）	不显著但值得注意	文本证据
第1回	蓬莱阁破船梦	无	罗盘(9次)、汉奸(8)、纪限仪(5)	「他们用的是外国罗盘，一定是洋鬼子差遣来的汉奸」
第2–4回	行医、听书、入抚署	鼓书(ratio 11.3)	宫保(88次)不显著	「明儿白妞说书，我们可以不必做生意，来听书罢」
第4–6回	曹州察玉贤	玉贤(7.9)、写信(9.5)	站笼被分词切碎	「只有十二架站笼，三天已满」
第7–11回	申东造、桃花山	申东造(9.5)、书信(23.6)	子平(56次)不显著	「将致刘仁甫的信亦写毕……交东造收了」
第12–20回	齐河破案	人瑞(2.0)、翠环(2.0)、翠花(2.2)	刚弼(27次)不显著	「食残的月饼……馅子里却是有点砒霜」

四、讨论：这些词为什么围绕老残

4.1 言说的两层结构：说道与写信

观察层面：说道在 sentence 法下与老残同句 17 次（ratio 1.8, p=0.013），是频次最高的言说动词；写信仅 2 次，但比值高达 9.5（p=0.016）；书信 obs=1，比值 23.6，是全表最高。

诠释层面：这组数字对应小说中两种截然不同的言说行为。日常对话里，老残是话轮的中心——第二回大明湖畔，「老残道：『天风海水，能移我情……』」，此类「老残道」句式贯穿全书，构成说道高频的基础。但真正推动情节的干预几乎都不发生在对话现场：曹州闻玉贤以站笼杀人，「只有十二架站笼，三天已满」，老残的反应不是当廷抗争，而是「将昨日未曾写完的信，详细写完封好」——写信给宫保；齐河贾魏氏冤案，他同样写信请白子寿出面平反。刚弼全书出现 27 次，却从未与老残显著共现，因为两人的对抗全程通过中介完成：批判者与被批判者在词汇层面被结构性地隔离开。低频高比值的写信、书信与高频低比值的说道，正是「主动诊断、间接干预」这一行为模式的词汇签名。

4.2 人物卫星即情节地图：人瑞、申东造、翠环

观察层面：人瑞在三种设定中均居首位（26/33/37 次），但比值仅 2.0–2.9；申东造比值 9.5；翠环、翠花只在 sentence 法显著。

诠释层面：这组词精确描画了老残社交半径随情节的推移。前半部（第1–9回）老残独来独往，几乎没有固定对话者，唯一的固定搭配是场所与套语；自第十二回黄河冰封、客店遇黄人瑞起，人瑞跃升为最高频搭配——「老残慌忙立起来看，正是黄人瑞」，此后两人几乎同进同出，议吏治、断冤案、叫局听书。申东造的高比值（9.5）则对应一段高强度的集中交往：第七回曹州之行前，两人连日论治盗，老残「将致刘仁甫的信亦写毕……交东造收了」。翠环、翠花只在整句法下显著，说明她们与老残的共现是事件性的（同处一室、同席吃饭），而非紧邻句法的修饰关系。

值得对照的是宫保：全书出现 88 次，却始终不显著。庄宫保是老残进入官场边缘的引路人，但他的高频是分散的——抚署公务语境中他无处不在，而与老残的共现只集中在几次会面。共现密度比绝对频率更能刻画人物关系，这是搭配分析优于词频统计的一个直接例证。

4.3 分身式主角：不在场的在场

观察层面：桃花山夜遇玓姑、黄龙子一段（第8–11回），正面对话者是申子平（全书 56 次），子平未达显著；而书信以 obs=1 达到全表最高比值 23.6。

诠释层面：这一段是全书最奇特的安排——老残的表弟申子平替他入山访贤，听玓姑解说《论语》、黄龙子论「北拳南革」。胡适序中引钱玄同的批评，说这段「神秘里夹杂着不少旧迷信」；但无论评价如何，结构上的事实是：老残不在场，他的观点却通过「老残所荐」「老残之意」被反复引用。刘仁甫是老残推荐的，子平是替老残去的，议题是老残设定的。搭配数据捕捉到了这种「分身」结构：子平高频而不显著（他与老残极少同框），书信低频而比值极高（它是老残意志的载体）。人物空间因此不必与肉身在場重合——主角的注意力份额可以被拆分给化身，而词汇引力仍归于本尊。

4.4 观察者的身体：看、坐、问

观察层面：一看（10 次，ratio 3.9）、坐下（13 次，4.2）、点点头、慌忙、连忙等动作词密集出现；几乎没有打、骂、跑类动词。地点词以门口、店里、河堤为主，时间词以次日、却说为主。

诠释层面：老残的身体动作几乎全是感知与应对——看、坐、听、问。他是游历的、旁观的、被接待的：住客店（店里）、站在门口、行至河堤，次日又启程。这套词汇组合描画出一个「移动的锚点」：他不定居、不掌权、不施刑，与玉贤、刚弼的「升堂—用

刑」空间形成系统性的对照。宫保的不显著在此获得第二重解释：老残不常待在官府公务语境里，他是「被请去建议，但不留任」的客位人物。

4.5 第1回的梦：身份的预支与词汇的滞后

观察层面：第1回蓬莱阁破船梦中，罗盘（9 次）、汉奸（8 次）、纪限仪（5 次）在三种设定下均未显著。

诠释层面：这不应读作分析的失败，而应读作文本的结构。梦中老残提议送破船「一个最准的罗盘，一个纪限仪」，船上人反驳「一定是洋鬼子差遣来的汉奸」——这是全书为老残定下的身份宣言：有技术、想介入、却被体制拒斥的观察者。但这一身份在词汇层面是宣示性的：梦境篇幅极短，共现密度不足以支撑统计显著。老残的观察者空间要到第二回以后——听书、行医、问案——才在搭配词中真正展开。身份先给、词汇后补，这种滞后只有把统计与细读并置才能看到。

五、与 Woloch 的对话

Woloch 的核心命题是：叙事注意力是稀缺资源，主角的突出性以压缩次要人物为代价；人物系统呈现「the one」与「the many」的结构性张力。本文的数据在三个层面上支持这一命题。

第一，突出性可量化。老残占 8.2% 的句子，其搭配词云高度集中——42 个跨设定稳定的核心词构成一圈清晰的词汇卫星。Woloch 所说主角「占据叙事空间」，在这里表现为可测量的共现密度。

第二，向心结构得到直接验证。以人瑞为目标词做对照分析，其 293 个显著搭配中，老残以 37 次高居第一。次要人物自己的词汇圈仍以主角为中心旋转——这正是 Woloch 所说次要人物作为主角功能之代行者（surrogate）的精确写照：人瑞存在的意义，很大程度上是为老残提供东道、信息与对话。

第三，注意力的高周转率。±5 窗口的 337 个显著搭配中约八成是该设定特有的临时组合；老残身边的词汇空间不断腾挪给下一个功能性人物。中心地位的维持不靠一组固定配角，而靠配角的持续轮替。

但数据同样暴露了 Woloch 模型的边界。其一，欧洲写实小说的主角通常占据家庭、客厅等固定空间，次要人物被压缩进这个稳定的容器；《老残游记》的老残却在店里、河堤、江南、东昌府之间移动，配角像驿站一样轮流出现。突出性的维持机制不是「压缩固

定配角」，而是「更换配角」——游记体对人物系统做了稀释处理。其二，Woloch 处理人物之间的注意力分配，但未处理「人物作为作者喉舌」的元层面。老残对宫保论治河、对申东造论治盗、经子平传递桃花山的三教议论，这些超情节的议论性搭配（写信、书信的高比值）表明，老残的词汇卫星承担着一个议论子空间——刘鹗自叙所谓「哭泣」，部分正是通过这个子空间发声。其三，救弱段的证据（翠环显著而哭、赎不显著）显示，叙事选择了行动记录而非情感陈述：翠环被执行拯救功能，其独立叙事重量在词汇层面相当稀薄。这印证了 Woloch 对次要人物工具化的担忧，但也提示：工具化在词汇上的表现不是「被贬低」，而是「只剩功能」。

六、方法的限制

窗口大小改变问题本身。±5、±10 与 sentence 不是同一问题的三种估计，而是三个不同的问题；取 42 词交集作为稳健核心，本身已是一种诠释决定。

分词误差系统性地压低检出率。站笼、白子寿、玓姑、黄龙子、千日醉、返魂香等关键词均被 jieba 切碎而消失于结果。加入自定义词典重跑后，高绍殷（比值 7.9）与玉贤转为显著，但多数专名仍不显著——切分损失只解释一部分，共现密度不足才是主因。对文言色彩浓厚的晚清白话小说，训练于现代语料的 jieba 存在系统偏差；未显著不等于无关联。

低频词的比值会虚高。书信比值 23.6 但仅出现 1 次；望外、狐裘比值 11.3 也只有 3 次。反之，宫保（88 次）、银子（109 次）等高频词的正确不显著，说明 Fisher 检验对均匀分布的背景词汇有良好鉴别力——这正是它优于 O/E 与 MI 之处，也是课程材料强调「把 p 值当分数来排序」的原因。

搭配词的根本盲区在于：它只知道老残身边有什么词，不知道叙事如何呈现他。视角（我们透过谁的眼睛看老残）、自由间接引语、反讽、他在场却沉默的段落，全部在词袋之外。第1回梦境的「身份预支」即是明证：统计上不显著，叙事上却是全书纲领。搭配词能画出人物空间的地图，画不出地图上的光线。

七、结语

本文以三种共现设定分析《老残游记》中老残的搭配词，并将统计结果放回文本细读。两条证据线共同描画出一个「哭泣的观察者」：他以言说（说道）与文书（写信、书信）介入世界，以感知动作（一看、坐下）而非权力动作（升堂、用刑）占据空间；他的身边围

绕着一圈轮替的功能性人物（人瑞、申东造、翠环），而非固定的配角群。这一分布量化地证实了 Woloch 的向心结构——连次要人物自己的词汇圈都以老残为中心——同时以游记体的配角轮替、分身式主角与议论子空间，修正了其以欧洲写实小说为底本的模型。数字给出分布，细读给出意义；两者接合处，正是数字人文处理文学人物的位置。

参考文献

1. 刘鹗：《老残游记》。艺文印书馆电子本（「好读书柜」典藏版，2014）。
2. 胡适：《老残游记》序（收入本书首）。
3. Woloch, Alex. *The One vs. the Many: Minor Characters and the Space of the Protagonist in the Novel*. Princeton UP, 2003.
4. Evert, Sebastian. "Corpora and Collocations." *Corpus Linguistics: An International Handbook*, Mouton de Gruyter, 2008.
5. qhchina: Digital humanities tools for Chinese studies, v0.2.5.
6. jieba: Chinese text segmentation library, v0.42.1.